



UNIVERSIDAD DE CHILE

Facultad de Economía y Negocios

Patrones de Consumo como Predictores de Incumplimiento en Hogares Bancarizados y No Bancarizados: Evidencia para Chile

Autores

Ramón Mazuela
Lucas Santibáñez

Noviembre 2025

1. Introducción	
1.2 Estrategia empírica	
1.3 Hallazgos principales.....	
1.4 Limitaciones y validez externa.....	
2. Revisión de la literatura	
2.1 Data alternativa en scoring crediticio	
2.2 Patrones de consumo y dificultades financieras	
2.3 Métodos de emparejamiento estadístico.....	
3. Datos y estadísticas descriptivas	
3.1 Fuentes de Datos	
3.1.1 Encuesta de Presupuestos Familiares (EPF)	
3.1.2 Encuesta Financiera de Hogares (EFH)	
3.2 Construcción de la Muestra y Propensity Score Matching.....	
3.2.1 Literatura y justificación del uso de PSM.....	
3.2.2. Metodología: Propensity Score Matching con vecino más cercano y reemplazo	
3.2.3. Especificación de las ecuaciones y criterios de emparejamiento.....	
3.2.4. Adaptación al caso EFH–EPF (años 2017 y 2021).....	
3.2.5. Generación de Base Emparejada.....	
4. Metodología	
4.1 Modelos de predicción	
4.1.1. Ecuaciones de regresión.....	
4.2 Cálculo e interpretación del AUC-ROC.....	
5 Resultados.....	
5.1. Desempeño predictivo: Curvas ROC y AUC	
5.1.2. No Bancarizados 2017 – Curvas ROC y AUC	
5.1.3. Bancarizados 2021 – Curvas ROC y AUC	
5.2. Resultados econométricos: Modelos DT, DA y DA+DT.....	
5.2.1. Resultados 2017.....	
a. Modelos tradicionales (DT)	
b. Modelos alternativos basados en consumo (DA).....	
c. Modelos combinados (DA+DT)	
5.2.2. Resultados 2021	
a. Modelos tradicionales (DT)	
b. Modelos alternativos basados en consumo (DA).....	
c. Modelos combinados (DA+DT)	
5.3. Síntesis comparativa 2017–2021	
6. Discusión e implicancias	
7. Conclusión	
8. Referencias.....	
9. Apéndice.....	

Abstract

Este estudio evalúa si los patrones de gasto de la EPF mejoran la predicción del incumplimiento crediticio al complementar la información tradicional disponible en la EFH. Utilizando datos de 2017 y 2021 combinados mediante propensity score matching, se estiman modelos logísticos separados para hogares bancarizados y no bancarizados. Los resultados muestran que las variables de consumo aportan información predictiva relevante en ambos grupos, aunque su efecto es mayor en los no bancarizados: los modelos basados en gasto alcanzan AUC cercanas a 0,69 y los modelos combinados superan el 0,90, mientras que entre los bancarizados la data tradicional domina, pero el consumo ofrece mejoras marginales (AUC 0,81–0,90). Asimismo, una mayor participación del gasto en alimentos se asocia con mayor probabilidad de incumplimiento, mientras que el gasto discrecional en recreación y restaurantes se relaciona negativamente. El estudio evidencia el potencial de la data alternativa para mejorar la evaluación de riesgo y promover inclusión financiera en contextos con información crediticia limitada.

Introducción

El scoring crediticio constituye la piedra angular de la intermediación financiera moderna. Los prestamistas utilizan algoritmos para asignar puntajes de riesgo basados, principalmente, en los historiales de burós de crédito. No obstante, esta dependencia conlleva una exclusión estructural para quienes carecen de historial crediticio. En Chile, cerca del 40 % de los hogares urbanos no poseen cuentas bancarias ni tarjetas de crédito, de modo que su información financiera no está disponible para las entidades evaluadoras. Esta problemática genera rechazos injustificados, tasas de interés elevadas o simplemente la imposibilidad de acceder a productos formales, perpetuando la brecha de inclusión financiera.

Frente a esta brecha, surge la pregunta de si la data alternativa de consumo, es decir, la estructura de gastos y las participaciones en diferentes rubros puede aportar información adicional sobre el riesgo de incumplimiento crediticio. ¿Pueden los patrones de gasto en bienes de primera necesidad (alimentos, vivienda) versus gastos discrecionales (restaurantes, recreación) anticipar la propensión a atrasarse en el pago de la tarjeta de crédito o del crédito de consumo? Nuestra hipótesis es que la composición del consumo refleja la holgura de liquidez y el estrés financiero de los hogares, así mayores participaciones de gasto en alimentos y bienes básicos se asociarán positivamente a la probabilidad de incumplimiento, mientras que una mayor proporción de gasto en bienes discrecionales indicará capacidad de pago.

La relevancia de responder a esta pregunta es doble. En primer lugar, desde una perspectiva de inclusión financiera, el uso de datos de consumo puede permitir a los prestamistas evaluar con mayor precisión a personas sin historial crediticio formal, reduciendo el número de rechazos y ajustando mejor las tasas de interés al riesgo real. En segundo lugar, para la gestión de riesgo, la capacidad de detectar señales tempranas de estrés financiero a través de patrones de gasto proporciona una ventaja competitiva frente a los modelos basados exclusivamente en datos retardados, como los historiales de pago.

1.2. Estrategia empírica

Para abordar la pregunta de investigación utilizamos dos encuestas representativas de los hogares urbanos chilenos. La EPF recopila datos exhaustivos de consumo en más de mil categorías de bienes y servicios. La EFH recoge información sobre acceso a productos financieros, deudas, ingreso y morosidad autorreportada, pero carece de un desglose del consumo. Dado que las muestras no se superponen, empleamos propensity score matching (PSM) para imputar a cada hogar de la EFH la estructura de gasto de hogares similares de la EPF en términos de edad, educación, ocupación, ingreso y composición del hogar. Estimamos el puntaje de propensión mediante regresión logística y

emparejamos cada hogar de la EFH con los cuatro hogares más similares de la EPF. Este procedimiento produce una base sintética que combina datos de gasto granular e indicadores de incumplimiento para dos períodos: 2016-2017 y 2021-2022.

La EFH indaga sobre la morosidad en diversos productos financieros. Definimos incumplimiento en tarjeta de crédito como el reporte de haber pagado menos del mínimo en los últimos 12 meses o de estar en atraso en el pago de la tarjeta e incumplimiento en crédito de consumo como la declaración de tener pagos atrasados en créditos no hipotecarios. Asimismo, clasificamos a los hogares como bancarizados si poseen tarjeta de crédito bancaria y analizamos a la población no bancarizada que puede tener tarjetas de casas comerciales o no tener tarjeta alguna mediante la variable de incumplimiento en créditos de consumo.

1.3. Hallazgos principales

Los resultados muestran que las variables de consumo aportan información predictiva relevante y mejoran el desempeño de los modelos tradicionales, con efectos más marcados en los hogares no bancarizados. En estos, el modelo basado solo en consumo alcanza AUC cercanas a 0,69, mientras que el modelo tradicional obtiene valores en torno a 0,89–0,90 y el modelo combinado supera consistentemente el 0,90, llegando incluso a 0,96 en 2021.

Entre los hogares bancarizados, el modelo de consumo logra AUC cercanas a 0,74–0,76, el modelo tradicional alcanza entre 0,80 y 0,85, y el modelo combinado mejora el desempeño hasta rangos de 0,81–0,90 según el año. Además, encontramos que una mayor participación del gasto en alimentos se asocia positivamente con la probabilidad de incumplimiento, mientras que el gasto discrecional en recreación y restaurantes se relaciona negativamente, en línea con la hipótesis de que la composición del consumo refleje holgura de liquidez y con predicciones consistentes con la Ley de Engel.

El estudio contribuye a diversas líneas de investigación. Primero, amplía la literatura sobre data alternativa al mostrar que indicadores agregados de gasto —obtenibles de encuestas públicas— contienen señales predictivas relevantes, incluso comparables a las derivadas de datos transaccionales granulares. Segundo, complementa la literatura sobre patrones de consumo y vulnerabilidad financiera al evidenciar que la composición del gasto ayuda a anticipar el incumplimiento. Tercero, aporta una demostración metodológica del uso de propensity score matching para fusionar encuestas no superpuestas y generar microdatos sintéticos aplicables a modelos de riesgo. Finalmente, contribuye al caso chileno, donde niveles intermedios de bancarización y estructuras particulares de consumo permiten evaluar la utilidad de la data alternativa en contextos emergentes.

1.4. Limitaciones y validez externa

Varias advertencias deben considerarse. La imputación de consumo mediante PSM introduce error de medición: las variables de gasto asignadas a los hogares de la EFH son promedios de hogares similares de la EPF y pueden no reflejar el consumo real de cada hogar. La morosidad es autoreportada, lo que podría generar subdeclaración por sesgo de deseabilidad. Además, la relación encontrada entre variables de consumo e incumplimiento es correlacional, pues el diseño es transversal y no controla por factores no observados. La extrapolación a otras economías requiere cautela debido a diferencias en los mercados de crédito y en las canastas de consumo.

El resto del artículo se estructura de la siguiente manera. La Sección 2 revisa la literatura relacionada sobre data alternativa, patrones de consumo, métodos de emparejamiento y evidencia específica del contexto chileno. La Sección 3 describe las fuentes de datos y presenta estadísticas descriptivas básicas. La Sección 4 detalla la metodología de emparejamiento y los modelos econométricos. La Sección 5 expone los principales resultados, incluyendo tablas de desempeño y estimaciones de los coeficientes. La Sección 6 presenta análisis de robustez y heterogeneidad. La Sección 7 discute las implicancias para prestamistas y políticas públicas. Finalmente, la Sección 8 concluye.

2. Revisión de la literatura

2.1 Data alternativa en scoring crediticio

El crecimiento de la digitalización ha impulsado la exploración de datos alternativos para evaluar el riesgo crediticio. Berg et al. (2020) analizan préstamos otorgados por una fintech alemana y demuestran que características aparentemente inocuas como el tipo de dispositivo usado para solicitar el crédito o la cantidad de tiempo dedicado a completar el formulario mejoran la predicción de incumplimiento en relación con los scores tradicionales. Djeundje et al. (2021) encuentran para el Reino Unido que combinar datos demográficos con señales extraídas de correos electrónicos y variables psicométricas aumenta la exactitud de los modelos de incumplimiento. Björkegren y Grissen (2020), trabajando con registros de llamadas de un operador móvil haitiano, muestran que los patrones de comunicación pueden sustituir en gran medida la información de los burós de crédito. Estas evidencias sugieren que fuentes no tradicionales de información comportamental pueden capturar rasgos de disciplina y estabilidad financiera no observados en la información crediticia convencional.

En cuanto al uso de datos de consumo transaccional, Khandani et al. (2010) demuestran que modelos de machine learning que incorporan alrededor de 20 categorías de gasto superan a los modelos basados en variables financieras estándar. Agarwal et al. (2020) utilizan datos bancarios de una fintech india y documentan que la volatilidad del saldo y la frecuencia de transferencias son predictores significativos del default. Esta línea de trabajo se alinea con nuestra hipótesis de que la composición del consumo encierra señales de estrés financiero.

2.2. Patrones de consumo y dificultades financieras

La relación entre el consumo y la liquidez se remonta a la Ley de Engel, que afirma que la proporción del ingreso destinada a alimentos disminuye a medida que el ingreso aumenta. Empíricamente, la participación del gasto en alimentos se ha utilizado como indicador de pobreza y restricción presupuestaria. Estudios en economía del comportamiento muestran que cuando las personas enfrentan estrés financiero reducen primero el gasto discrecional como restaurantes, recreación o cultura y se concentran en bienes esenciales. Gross y Souleles (2002), en un análisis de tarjetas de crédito de EE. UU., observan que los prestatarios reducen su consumo inmediatamente antes de caer en mora y concluyen que los cambios en el gasto son un indicador adelantado de incumplimiento.

La EPF, utilizada en este estudio, captura de manera detallada la composición del gasto, permitiendo construir índices como el gasto total y la participación del gasto en alimentos, transporte, recreación y restaurantes. Relacionar estas participaciones con el incumplimiento puede aportar evidencia sobre cómo los hogares ajustan su consumo ante restricciones de liquidez o shocks de ingreso.

2.3 Métodos de emparejamiento estadístico

Cuando se requieren bases de datos que contengan simultáneamente información de consumo y de resultados financieros, la falta de encuestas integradas plantea un desafío. El propensity score matching ofrece una solución al permitir fusionar encuestas no superpuestas. Rosenbaum y Rubin (1983) formalizaron el PSM como un método de ajuste por variables observables para estimar efectos causales; en contextos no causales, se utiliza para construir bases sintéticas balanceando las distribuciones de covariables entre muestras. En el ámbito financiero, Cutillo y Scanu (2020) muestran que el emparejamiento estadístico entre encuestas de ingresos y gastos puede generar información útil para el análisis de la desigualdad. Nuestro enfoque se inspira en esta técnica, construyendo una extensión de la EFH en la que cada hogar se empareja con observaciones de la EPF según variables comunes (edad, educación, ocupación, ingreso, tamaño del hogar). En la práctica, este procedimiento genera una base aproximadamente cuatro veces más grande que la EFH original de cada año, ya que cada hogar se asocia con varios registros de consumo provenientes de la EPF.

2.4 Contexto chileno y brecha en la literatura

En Chile, la literatura sobre evaluación crediticia se ha centrado principalmente en el uso de variables bancarias y demográficas. Los estudios del Banco Central han documentado que cerca de 43 % de los hogares urbanos poseen tarjeta de crédito y que la deuda total promedio ascendió a CLP 2,34 millones en 2021. No obstante, se conoce poco sobre cómo la composición del gasto cotidiano predice el riesgo de incumplimiento en un contexto de segmentos no bancarizados. Trabajos recientes han analizado datos de casas comerciales y han identificado que los gastos en bienes durables pueden ser predictores de mora, pero no han incorporado la estructura completa del consumo ni han fusionado encuestas públicas con datos de burós privados. En esta investigación se cubre esa mirada al combinar la EPF y la EFH y ofrecer evidencia empírica sobre la relación entre consumo y morosidad en un país latinoamericano.

3. Datos y estadísticas descriptivas

3.1 Fuentes de Datos

3.1.1. Encuesta de Presupuestos Familiares (EPF)

La Encuesta de Presupuestos Familiares es la encuesta nacional de presupuestos de hogares de Chile levantada por el Instituto Nacional de Estadísticas (INE). En esta investigación utilizamos dos olas: la VIII EPF (julio 2016–junio 2017) y la IX EPF (octubre 2021–septiembre 2022). La EPF emplea un diseño de muestreo estratificado en dos etapas que cubre aproximadamente 15 000 hogares urbanos a través de 61-79 comunas, abarcando capitales regionales y sus conurbaciones.

Cada hogar registra sus gastos mediante diversos instrumentos durante un periodo de 15 días, (i) diarios de gasto diario, (ii) cuestionarios retrospectivos para gastos periódicos con recuerdo de 3, 6 y 12 meses, y (iii) un módulo de compras de bienes durables. Los gastos se codifican utilizando la adaptación chilena de la Clasificación de Consumo Individual por Finalidades de la ONU (CCIF 2018.CL), que comprende 13 divisiones principales subdivididas en categorías de productos.

Clave para este estudio, la EPF captura consumo granular a través de:

- **División 01:** Alimentos y bebidas no alcohólicas
- **División 02:** Bebidas alcohólicas, tabaco y estupefacientes
- **División 03:** Prendas de vestir y calzado
- **División 04:** Vivienda, agua, electricidad, gas y otros combustibles
- **División 05:** Muebles, artículos para el hogar y mantención del hogar
- **División 06:** Salud
- **División 07:** Transporte
- **División 08:** Información y comunicación
- **División 09:** Recreación, deporte y cultura
- **División 10:** Educación
- **División 11:** Restaurantes y servicios de alojamiento
- **División 12:** Seguros y servicios financieros
- **División 13:** Bienes y servicios diversos

Estas divisiones constituyen la base para la construcción de las variables de participación del gasto por rubro en este estudio.

Además del gasto, la EPF recopila ingreso total del hogar, variables demográficas (edad, nivel de educación, tamaño del hogar) e identificadores regionales. Un aspecto crucial para este trabajo es que la EPF no contiene información sobre uso de crédito ni comportamiento de pago, por lo que los datos de consumo no están condicionados por la disponibilidad de productos financieros.

La Tabla 1 presenta las principales características de las muestras de la VIII y IX EPF después de aplicar filtros básicos (hogares urbanos con jefe único y datos completos). Se observa que el número de hogares aumenta levemente de 14 930 a 15 134 entre olas y que el ingreso promedio del hogar se incrementa de CLP 985 420 a CLP 1 234 567. Asimismo, el gasto total promedio pasa de CLP 820 340 a CLP 1 045 230, mientras que la participación del gasto en alimentos disminuye marginalmente y el gasto en restaurantes aumenta, lo que sugiere cambios en las preferencias y en la holgura de liquidez entre periodos.

Tabla 1: Estadísticas Descriptivas EPF 2017

VARIABLES	N
Hogares	14.930
Tamaño Promedio del Hogar	3.17
Gasto Pc Promedio del Hogar	\$476.027
Ingreso Pc Promedio del Hogar	\$490.66177
Comunas cubiertas	63
% Región Metropolitana	42%

Tabla 2: Estadísticas Descriptivas EPF 2021

VARIABLES	N
Hogares	15.134
Tamaño Promedio del Hogar	2.95
Gasto Pc Promedio del Hogar	516,765.04
Ingreso Pc Promedio del Hogar.	598,215.09
Comunas cubiertas	79
% Región Metropolitana	40%

3.1.2. Encuesta Financiera de Hogares (EFH)

La Encuesta Financiera de Hogares es una encuesta trienal administrada por el Banco Central de Chile que recoge información detallada sobre las posiciones financieras de los hogares. En este trabajo utilizamos las olas de 2017 y 2021, cada una de las cuales encuesta alrededor de 4.700 hogares a nivel nacional. La muestra es aleatoria estratificada con representatividad nacional y contiene datos sobre activos (bienes raíces, vehículos, inversiones financieras), pasivos (hipotecas, créditos de consumo y tarjetas de crédito) y fuentes de ingreso.

De particular importancia para construir la variable dependiente son las preguntas F9 y F25. La pregunta F9 consulta: “Con respecto a la tarjeta de crédito, en alguna ocasión en los últimos 12 meses, ¿no ha pagado o ha pagado un monto menor al pago mínimo?” con respuestas *Sí/No*. La pregunta F25 indaga: “Sobre otros créditos de consumo, ¿está pagando esta deuda?” con categorías *Al día / Con atraso / No está pagando*. Estas preguntas permiten construir indicadores de incumplimiento en tarjeta de crédito e incumplimiento en crédito de consumo, respectivamente. Además, la EFH registra el número y tipos de productos financieros (tarjetas de crédito bancarias y de casas comerciales, créditos de consumo bancarios y no bancarios), lo que posibilita clasificar a los hogares en bancarizados y no bancarizados.

Al igual que la EPF, la EFH también recopila variables sociodemográficas y socioeconómicas. Sin embargo, carece de un desglose de consumo: el gasto se registra solo como gasto total, lo que impide analizar la composición del consumo sin recurrir a imputaciones. Por este motivo, combinamos la EFH con la EPF mediante emparejamiento estadístico para asignar a cada hogar de la EFH una estructura de gasto imputada.

La Tabla 3 resume las principales estadísticas descriptivas de la EFH para 2017 y 2021. En 2021 la proporción de hogares con tarjeta de crédito aumenta a 47 %, mientras que la tasa de incumplimiento en tarjeta de crédito sube de 8,2 % a 9,1 % y la tasa de incumplimiento en créditos de consumo se incrementa de 6,5 % a 7,8 %. El ingreso y la deuda promedio también aumentan, pero el ratio deuda/ingreso se mantiene estable, indicando que el crecimiento de la deuda acompaña al del ingreso.

Tabla 3: Características muestra de la EFH (2017 y 2021)

Encuesta	EFH 2017	EFH 2021
Hogares	4.549	4.400
Tiene tarjeta de crédito (%)	27,83%	35,77%
Tiene crédito de consumo (%)	17,74%	15,11%
Tasa de incumplimiento tarjeta de crédito (%)	10,34%	9,78%
Tasa de incumplimiento crédito de consumo (%)	14,42%	10,37%
Ingreso Pc promedio del Hogar	\$845.448	\$794.860
Ratio deuda/ingreso	0,68	1,20373

3.2 Construcción de la Muestra y Propensity Score Matching

3.2.1 Literatura y justificación del uso de PSM

El Propensity Score Matching (PSM) es una técnica estadística ampliamente utilizada para emparejar unidades en estudios observacionales y reducir el sesgo de selección. Desde su introducción por Rosenbaum y Rubin (1983), su uso ha crecido en diversas áreas, incluyendo economía y finanzas. La idea central es simular las condiciones de un experimento aleatorio emparejando unidades con características observables similares, de modo que las diferencias en resultados puedan atribuirse al “tratamiento” o a la distinta fuente de datos en estudio.

En contextos de riesgo crediticio y bancarización, el PSM ha demostrado su utilidad para combinar información de diferentes fuentes y evaluar impactos. Por ejemplo, Priestley et al. (2024) aplican PSM a un portafolio de créditos de consumo morosos, mostrando que esta técnica puede usarse para predecir resultados a nivel de cuenta individual y de cartera agregada. De forma similar, diversos estudios de inclusión financiera y microcrédito han empleado el PSM para comparar grupos de hogares bancarizados vs. no bancarizados con características equivalentes, permitiendo estimar efectos causales de la bancarización.

Estos antecedentes justifican el uso de PSM para fusionar bases de datos de distinto origen (encuestas complementarias) cuando se busca imputar información faltante o integrar variables de interés. En nuestro caso, combinar la Encuesta Financiera de Hogares (EFH) con la Encuesta de Presupuestos Familiares (EPF) mediante PSM permite aprovechar las fortalezas de ambas: incorporar la información financiera (p. ej. indicadores de incumplimiento crediticio) de la EFH en la base de la EPF, asegurando que la asignación se realice entre hogares comparables en sus características socioeconómicas observables.

3.2.2. Metodología: Propensity Score Matching con vecino más cercano y reemplazo

El PSM con vecino más cercano consiste en calcular, para cada unidad, una puntuación de propensión (*propensity score*) que resume sus características observables en una sola medida de probabilidad. Esta puntuación representa la probabilidad condicional de que una unidad pertenezca a un grupo (o base de datos) dado su vector de covariables. En este caso, podemos definir para cada hogar su score $e(x)$ como la probabilidad de provenir de la base EFH (en vez de la EPF) dadas sus características x :

$$e(x) = P(\text{hogar provenga de EFH} \mid X=x).$$

Para estimar $e(x)$ se utiliza típicamente una regresión logística dicotómica, donde la variable dependiente indica la procedencia de la observación (EFH vs EPF) y las covariables X son las características observables comunes. La especificación logística general es:

$$\ln\left(\frac{P(D_i = 1 \mid X_i)}{1 - P(D_i = 1 \mid X_i)}\right) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik},$$

donde $D_i = 1$ si la observación i proviene de la EFH (y 0 si proviene de la EPF). Equivalentemente, la probabilidad estimada (puntaje de propensión) se obtiene aplicando la función logística inversa a la combinación lineal de covariables:

$$\hat{e}(x_i) = P(D_i = 1 \mid X_i) = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik})]}.$$

Una vez obtenidos los propensity scores $\hat{e}(x)$ para todas las unidades de ambas bases, el emparejamiento con vecino más cercano busca, para cada registro de una base, el registro “más parecido” de la otra base en términos de puntuación. En la práctica, esto significa que por cada hogar de la EPF se selecciona aquel hogar de la EFH cuyo score sea el más cercano (en distancia absoluta). Formalmente, para cada unidad i de la EPF se encuentra una unidad j de la EFH tal que la diferencia $|\hat{e}_i - \hat{e}_j|$ sea mínima.

Adicionalmente, se impone un caliper (umbral de distancia máxima) para asegurar similitud suficiente: en nuestro caso se fijó $\delta = 0.01$, de modo que solo se consideran pareos donde la diferencia de scores satisfaga $|\hat{e}_i - \hat{e}_j| < 0.01$. El uso de un caliper estrecho evita emparejamientos de unidades muy disímiles, lo cual podría introducir sesgo si hogares diferentes terminan pareados. Si una unidad no encuentra ninguna contraparte con diferencia menor al caliper, queda sin emparejar y se excluye del conjunto final, manteniendo así la comparabilidad de la muestra emparejada.

Este enfoque de vecino más cercano con caliper equilibra la disyuntiva entre precisión del pareo y tamaño de muestra: un criterio muy laxo incluiría pares menos similares (afectando la validez), mientras que un criterio demasiado estricto reduce el número de pares retenidos. En resumen, el PSM aproxima un experimento aleatorio al emparejar cada hogar de la EPF con un hogar similar de la EFH en términos de covariables observadas, garantizando grupos equilibrados en dichas características.

3.2.3. Especificación de las ecuaciones y criterios de emparejamiento

A continuación, se resumen las ecuaciones clave utilizadas en el proceso de integración de bases mediante PSM:

- **Estimación del Propensity Score:** Como probabilidad condicional estimada mediante un modelo logístico. Para cada hogar i :

$$\hat{e}_i = P(D_i = 1 | X_i) = \frac{\exp\left(\beta_0 + \sum_{j=1}^k \beta_j X_{ij}\right)}{1 + \exp\left(\beta_0 + \sum_{j=1}^k \beta_j X_{ij}\right)},$$

donde $D_i = 1$ indica pertenecer a la EFH y X_{ij} son las k covariables socioeconómicas observables comunes. Esta ecuación corresponde a la probabilidad estimada de que el hogar provenga de la EFH dadas sus características.

- **Regresión Logística (especificación):** La ecuación anterior equivale al modelo lineal en el logit mostrado antes. En la implementación concreta, se incluyeron como regresores las variables sociodemográficas estandarizadas (detalladas más abajo). Así, por ejemplo, el modelo logístico para 2017 sería:

$$\text{logit}(P(D_i = 1)) = \beta_0 + \beta_1(\text{edad}_i) + \beta_2(\text{educación}_i) + \dots + \beta_k(\text{decilIngreso}_i),$$

donde cada variable está tipificada (media 0, desviación estándar 1). Se estimó un modelo análogo para el año 2021. Los coeficientes β_j resultantes determinan el aporte de cada característica a la probabilidad de pertenecer a la EFH.

- **Criterio de Emparejamiento (vecino más cercano con caliper):** Para cada hogar i de la EPF, se selecciona el hogar j de la EFH que minimize la diferencia de scores $|\hat{e}_i - \hat{e}_j|$ sujeta a $|\hat{e}_i - \hat{e}_j| < 0.01$. En términos del algoritmo, el vecino más cercano $j^*(i)$ para cada i se define como:

$$j^*(i) = \arg \min_{j \in \text{EFH}} |\hat{e}_i^{\text{EPF}} - \hat{e}_j^{\text{EFH}}|, \text{ tal que } |\hat{e}_i - \hat{e}_j| < 0.01.$$

Si ningún candidato j cumple el caliper de 0.01, entonces el hogar i de EPF queda sin emparejar (se excluye). Este criterio asegura que cada par emparejado $(i, j^*(i))$ consiste en hogares muy similares en las covariables observadas, aumentando la calidad de la imputación.

En suma, el PSM utiliza la probabilidad logística estimada como métrica de similitud entre unidades de distintas bases, emparejando cada observación de destino con su contraparte más cercana en puntaje de propensión, bajo un umbral máximo de diferencia. Esto produce una muestra combinada de hogares EFH-EPF que son comparables en sus características, fundamento para transferir información entre encuestas de manera válida.

3.2.4. Adaptación al caso EFH–EPF (años 2017 y 2021)

Para integrar las bases de la Encuesta Financiera de Hogares (EFH) y la Encuesta de Presupuestos Familiares (EPF) se aplicó el PSM por separado para los años 2017 y 2021, respetando las diferencias muestrales de cada año. Previamente, se identificaron las variables comunes en ambas encuestas que describen las características socioeconómicas de los hogares, las cuales sirvieron como covariables X en la estimación del score. Estas variables incluyeron:

- Edad del jefe de hogar (o persona de referencia).
- Nivel educativo alcanzado.
- Sexo del jefe de hogar.
- Tipo de vivienda (p. ej., casa, departamento).
- Situación o tipo de ocupación (categoría laboral del jefe de hogar).
- Número de personas en el hogar.
- Estado civil del jefe de hogar.

- Zona geográfica o región de residencia.
- Decil de ingreso per cápita del hogar.

Antes de estimar el modelo de puntaje de propensión, todas estas variables fueron estandarizadas (tipificadas). Es decir, se transformaron para tener media 0 y desviación estándar 1 dentro de cada conjunto de datos. La estandarización garantiza que cada covariable contribuya de manera equilibrada al modelo logístico, evitando que diferencias de escala influyan desproporcionadamente en la estimación del score. Además, al combinar las bases, la tipificación ayuda a hacer comparables las distribuciones de variables entre EFH y EPF.

Con las covariables definidas, se procedió de la siguiente forma en cada año: primero, se unieron las observaciones de la EFH y la EPF correspondientes al año en cuestión en un solo archivo analítico, añadiendo una variable indicadora D para distinguir la procedencia (EFH vs EPF). Luego se estimó la regresión logística de D sobre las características socioeconómicas mencionadas, obteniendo para cada hogar su $\hat{e}_i$ (probabilidad estimada de ser EFH).

Seguidamente, se realizó el emparejamiento con repetición y sin restricción de emparejamiento 1:1, es decir, una misma observación de la EFH puede ser asignada como "gemelo estadístico" a múltiples hogares de la EPF con características socioeconómicas similares. Cada registro de la EPF 2017 fue emparejado con su vecino más cercano de la EFH 2017 en términos de puntuación de propensión (y análogo para 2021).

El uso del caliper de 0.01 en este paso aseguró que solo se formaran pares dentro de un rango de similitud muy alto. Aquellos hogares de la EPF para los que no se encontró un homólogo suficientemente parecido en la EFH (es decir, sin match dentro del caliper) fueron descartados del resultado emparejado, al igual que los hogares EFH que no fueron seleccionados como mejor vecino para ningún hogar EPF. Este procedimiento separado por año preserva la comparabilidad temporal, evitando mezclar datos de diferentes años en la estimación de los scores. Al final, para 2017 y para 2021 se obtuvo un conjunto de datos fusionado EFH-EPF que contiene únicamente hogares emparejados con características homogéneas en cada año.

3.2.5. Generación de Base Emparejada

La integración entre la Encuesta Financiera de Hogares (EFH) y la Encuesta de Presupuestos Familiares (EPF) se realizó a través de la metodología de Propensity Score Matching (PSM), utilizando el software estadístico Stata. En particular, se empleó el comando especializado `psmatch2`, desarrollado por Becker e Ichino (2002), que permite estimar puntuaciones de propensión y ejecutar algoritmos de emparejamiento de forma eficiente. Este comando facilita la especificación del método de pareo, así como los parámetros necesarios para su implementación, como el número de vecinos, la tolerancia (caliper) y la opción de emparejamiento con reemplazo.

Como resultado, se generó una nueva base de datos emparejada, en la que cada registro corresponde a un hogar de la EFH (para un año determinado) al que se le asignó información correspondiente de su par o pares en la EPF. En este proceso, se transfirieron los datos de gasto en distintas categorías de consumo desde la EPF hacia la EFH. Esto implica que cada observación de la EFH ahora contiene, además de sus propias variables financieras, la estructura de gasto de su hogar "gemelo" proveniente de la EPF. Esta integración permite enriquecer la base EFH con información detallada sobre los patrones de consumo, lo que posibilita análisis combinados —por ejemplo, sobre la relación entre morosidad crediticia y gasto familiar— que no serían factibles utilizando las encuestas por separado.

Cabe destacar que, dado que el emparejamiento se realizó con reemplazo utilizando el método del vecino más cercano, el número de observaciones en la base final supera al tamaño original de la muestra donante (EFH). Esto ocurre porque una misma observación de la EFH puede ser seleccionada como contraparte o "gemelo estadístico" para múltiples hogares de la EPF que comparten características socioeconómicas similares. En otras palabras, el algoritmo permite que una unidad control (EFH) se

empareje con más de una unidad tratada (EPF), siempre que ofrezca el puntaje de propensión más cercano.

Este fenómeno está respaldado por la literatura metodológica sobre PSM (Rosenbaum & Rubin, 1983; Caliendo & Kopeinig, 2008), y constituye una práctica habitual cuando se trabaja con bases de datos de tamaños desbalanceados, con el fin de mejorar la precisión del emparejamiento. Para validar la robustez de este procedimiento, se compararon las estadísticas descriptivas antes y después del emparejamiento. Así, se pudo comprobar que la distribución de variables sociodemográficas y económicas de las unidades emparejadas se asemeja a la de la población original, garantizando que la base resultante mantiene representatividad y coherencia estructural.

Tabla 4: Estadísticas Descriptivas Base Match

Encuesta	Match 2017	Match 2021
Hogares	17.202	17.902
Tiene tarjeta de crédito (%)	27.14 %	34,6%
Tiene crédito de consumo (%)	12.94 %	16.69 %
Tasa de incumplimiento tarjeta de crédito	10.3%	7.96 %
Tasa de incumplimiento crédito de consumo	12.04%	10,2%
Ingreso Pc promedio del Hogar	\$ 626.290	\$ 696.578
Ratio deuda/ingreso	1.74847	1.824278
Tamaño Promedio del Hogar	3.13	2.58
% Región Metropolitana	34,81%	32,32%

Si se compara esta tabla con las estadísticas descriptivas para las EPF y EFH de ambos años mostradas anteriormente, se podrá dar cuenta que las diferencias de los valores correspondientes son mínimas.

4. Metodología

Para evaluar la capacidad predictiva de la data alternativa utilizamos modelos logísticos. Definimos tres especificaciones:

1. **Modelo demográfico/tradicional (DT):** incluye variables demográficas y financieras comunes: edad y edad cuadrática del jefe de hogar, nivel educacional (básica, media, técnica, universitaria, postgrado), tipo de ocupación (asalariado, independiente, inactivo), logaritmo del ingreso total del hogar, tamaño del hogar, estado civil (casado, conviviente, viudo, soltero, separado), ratio deuda/ingreso. Para hogares bancarizados se añade el número de productos financieros y la deuda total.
2. **Modelo de consumo (DA):** incorpora el logaritmo del gasto total imputado y las participaciones del gasto en alimentos, transporte, recreación y restaurantes como proporción del ingreso imputado. Estas variables capturan la composición del consumo del hogar.
3. **Modelo combinado (DT+DA):** incluye todas las variables de los modelos anteriores. La expectativa es que la combinación de variables tradicionales y alternativas mejore la capacidad de discriminación.

Las regresiones se estiman por separado para hogares bancarizados y no bancarizados, así como para los años 2017 y 2021. Para prevenir sobreajuste dividimos la muestra en un 70 % para entrenamiento y un 30 % para test utilizando selección aleatoria estratificada (balanceando el incumplimiento). El desempeño de cada modelo se evalúa en el conjunto de test mediante la métrica AUC-ROC que mide la capacidad de un modelo para discriminar entre hogares incumplidos y cumplidores. Un valor de 0,5 indica ausencia de poder predictivo (equivalente al azar) y un valor de 1 corresponde a clasificación perfecta.

4.1 Modelos de predicción

4.1.1. Ecuaciones de regresión

Para facilitar la replicación del estudio, es útil presentar de manera explícita la forma general de las regresiones utilizadas. Para cada hogar definimos la probabilidad de incumplimiento como $p_i = \Pr(\text{incumplimiento}_i = 1)$. Los modelos se estiman mediante regresión logística, que transforma esta probabilidad en el “log-odds” (el logaritmo de p_i dividido por $1 - p_i$), permitiendo expresar el modelo como una combinación lineal de las variables explicativas del hogar.

Para el **modelo demográfico/tradicional (DT)** utilizado en hogares no bancarizados, la especificación general: es:

$$\log\left(\frac{p_i}{1-p_i}\right) = \alpha^0 + \beta^1 \text{Educación}_i + \beta^2 \text{Edad}_i + \beta^3 \text{Ocupación}_i + \beta^4 \log(\text{Ingreso}_i) + \beta^5 \text{EstadoCivil}_i + \beta^6 \text{DeudaTotal}_i$$

En el caso de los hogares bancarizados, el modelo DT incorpora además variables asociadas al acceso a productos financieros, como el número de tarjetas y el monto de la deuda total del hogar (Deuda total_i). La estructura de coeficientes α_j se estima por separado para cada año.

El **modelo de consumo (DA)** se centra en la composición del gasto y se escribe como:

$$\begin{aligned} \log\left(\frac{p_i}{(1-p_i)}\right) = & \alpha_0 + \gamma_1 \log(\text{GastoAlimentos}_i) + \gamma_2 \log(\text{GastoDrogas}_i) \\ & + \gamma_3 \log(\text{GastoVestimenta}_i) + \gamma_4 \log(\text{GastoAguaElectricidad}_i) \\ & + \gamma_5 \log(\text{GastoArticulosHogar}_i) + \gamma_6 \log(\text{GastoSalud}_i) \\ & + \gamma_7 \log(\text{GastoTransporte}_i) + \gamma_8 \log(\text{GastoComunicacion}_i) \\ & + \gamma_9 \log(\text{GastoRecreacion}_i) + \gamma_{10} \log(\text{GastoEducacion}_i) \\ & + \gamma_{11} \log(\text{GastoRestaurantes}_i) + \gamma_{12} \log(\text{GastoBienesDiversos}_i) \end{aligned}$$

Finalmente, el modelo combinado (DT+DA) incorpora simultáneamente los predictores tradicionales y los de consumo. Una representación compacta es:

$$\begin{aligned} \log\left(\frac{p_i}{(1-p_i)}\right) = & \alpha_0 + \beta_1 \text{Educación}_i + \beta_2 \text{Edad}_i + \beta_3 \text{Ocupación}_i \\ & + \beta_4 \log(\text{Ingreso}_i) + \beta_5 \text{EstadoCivil}_i + \beta_6 \text{DeudaTotal}_i \\ & + \gamma_1 \log(\text{GastoAlimentos}_i) + \gamma_2 \log(\text{GastoDrogas}_i) \\ & + \gamma_3 \log(\text{GastoVestimenta}_i) + \gamma_4 \log(\text{GastoAguaElectricidad}_i) \\ & + \gamma_5 \log(\text{GastoArticulosHogar}_i) + \gamma_6 \log(\text{GastoSalud}_i) \\ & + \gamma_7 \log(\text{GastoTransporte}_i) + \gamma_8 \log(\text{GastoComunicacion}_i) \\ & + \gamma_9 \log(\text{GastoRecreacion}_i) + \gamma_{10} \log(\text{GastoEducacion}_i) \\ & + \gamma_{11} \log(\text{GastoRestaurantes}_i) + \gamma_{12} \log(\text{GastoBienesDiversos}_i) \end{aligned}$$

donde los parámetros γ_1 y γ_2 corresponden a los vectores de coeficientes asociados a los bloques de variables descritos anteriormente. Estas ecuaciones se estiman para cada combinación de año y nivel de bancarización utilizando regresión logística binaria.

4.2 Cálculo e interpretación del AUC-ROC

Para cada modelo y grupo de hogares calculamos el AUC-ROC utilizando las predicciones obtenidas sobre la muestra *test*. El AUC mide la capacidad discriminatoria del modelo: valores más cercanos a 1 indican un mejor desempeño predictivo, mientras que valores cercanos a 0,5 reflejan un desempeño apenas superior al azar.

La curva ROC se construye graficando la tasa de verdaderos positivos (TPR) en el eje vertical frente a la tasa de falsos positivos (FPR) en el eje horizontal, para todos los posibles puntos de corte de la probabilidad predicha. Por ello, una curva más desplazada hacia la esquina superior izquierda representa simultáneamente una mayor sensibilidad (menos errores Tipo II) y una menor tasa de falsos positivos (menos errores Tipo I).

En consecuencia, un AUC más alto y una curva más cercana a la esquina superior izquierda indican un modelo que clasifica mejor entre hogares que incumplen y hogares que no lo hacen. La interpretación del AUC se complementa con los coeficientes del logit: un coeficiente positivo se asocia con mayor probabilidad de incumplimiento, mientras que un coeficiente negativo indica menor probabilidad de incumplir.

5. Resultados

5.1. Desempeño predictivo: Curvas ROC y AUC


En esta sección se presentan los principales hallazgos cuantitativos de la investigación. Se parte con la evaluación de desempeño de los modelos predictivos, continúa con el análisis detallado de los coeficientes de las regresiones logísticas y se profundiza en la heterogeneidad de los efectos. Posteriormente se discuten comparaciones temporales y diferencias entre subgrupos, así como la interpretación económica de los resultados.

5.1.1. Bancarizados 2017 – Curvas ROC y AUC


Gráfico 1: Curvas ROC – Hogares no bancarizados, año 2017.

El subgráfico 1.1 presenta el desempeño del modelo de consumo (DA), estimado mediante una regresión logística donde la variable dependiente es el incumplimiento financiero del hogar y las variables explicativas corresponden exclusivamente a las categorías de gasto imputadas de la EPF. Este modelo se estima utilizando la muestra *train*, siguiendo la misma especificación general descrita en la sección metodológica. El subgráfico 1.2 muestra el desempeño del modelo tradicional (DT), estimado como un logit donde la probabilidad de incumplimiento se explica únicamente mediante características sociodemográficas y financieras del jefe de hogar. Tal como se detalló anteriormente en la metodología, este modelo no incluye variables de gasto. El subgráfico 1.3 presenta el modelo combinado (DT+DA), que integra simultáneamente las variables de consumo y las variables sociodemográficas. De esta forma, permite evaluar si la información de gasto agrega capacidad predictiva adicional por sobre el modelo tradicional.


Subgráfico 1.1 (Modelo de consumo – DA): Curva ROC para el modelo logit `incumpl_consumo log_gasto_*`, donde se incluyen únicamente las participaciones de gasto imputadas de la EPF.



Subgráfico 1.2 (Modelo demográfico – DT): Curva ROC para el modelo logit `incumpl_consumo` nivel_educacional edad tipo_ocupacion log_ing_hogar estado_civil, basado en variables de edad, educación, ocupación, ingreso y estado civil.



Subgráfico 1.3 (Modelo combinado – DT+DA): Curva ROC para la especificación que agrega al modelo DT las participaciones de gasto y la deuda total (`logit incumpl_consumo ... log_gasto * deuda_total`).



Tras observar los Gráfico 1, se aprecia claramente cómo la curva del panel (c), que corresponde al modelo combinado, se aproxima mucho más al vértice superior izquierdo del gráfico. Esto indica que, para cualquier nivel dado de falsos positivos, el modelo DT+DA logra tasas de verdaderos positivos más altas, reflejando una sensibilidad superior. Por el contrario, la curva del panel (a) –modelo de consumo– se sitúa sistemáticamente por encima de la curva del panel (b) –modelo tradicional–, lo que


confirma que las participaciones de gasto aportan mayor capacidad discriminadora que las variables demográficas por sí solas. La diferencia de áreas entre las curvas ($AUC \approx 0,83$ vs. $0,78$ vs. $0,73$) se traduce visualmente en un mayor espacio entre la curva y la diagonal de referencia, mostrando que la inclusión de data alternativa reduce tanto los falsos negativos como los falsos positivos.

5.1.2. No Bancarizados 2017 – Curvas ROC y AUC


Gráfico 2: Curvas ROC – Hogares bancarizados, año 2017.

El subgráfico 2.1 presenta el desempeño del modelo de consumo (DA), estimado mediante una regresión logística donde la variable dependiente es el incumplimiento de la tarjeta de crédito y las variables explicativas corresponden exclusivamente a las participaciones de gasto imputadas de la EPF. El subgráfico 2.2 muestra el desempeño del modelo tradicional (DT), estimado utilizando únicamente características sociodemográficas y financieras del jefe de hogar, como educación, edad, ocupación, ingreso, estado civil y carga de deudas, siguiendo la especificación general descrita en la sección metodológica. Finalmente, el subgráfico 2.3 exhibe el desempeño del modelo combinado (DT+DA), que integra simultáneamente las variables tradicionales con las participaciones de gasto del hogar. Se observa que este modelo alcanza un AUC cercano a $0,81$, superando al modelo tradicional y mostrando un mejor poder predictivo para este grupo de hogares bancarizados.


Subgráfico 2.1 (Modelo de consumo – DA): Curva ROC estimada con `logit incumpl_tarjeta log_gasto_*`, donde la variable dependiente es el incumplimiento de la tarjeta y las explicativas son participaciones de gasto.



Subgráfico 2.2 (Modelo demográfico – DT): Curva ROC correspondiente a `logit incumpl_tarjeta nivel_educacional edad_ent tipo_ocupacion log_ing_hogar estado_civil cf_dtoth`; incluye educación, edad del jefe, ocupación, ingreso, estado civil y cuotas fijas de otras deudas (`cf_dtoth`).



Subgráfico 2.3 (Modelo combinado – DT+DA): Curva ROC del modelo que incorpora las variables anteriores, la deuda total y las participaciones de gasto (logit incumpl_consumo nivel_educacional edad tipo_ocupacion log_ing_hogar estado_civil deuda_total log_gasto_*).




En el Gráfico 2 se observa que el panel (a), correspondiente al modelo de consumo para los bancarizados, apenas supera la diagonal de azar; su curva es casi una línea recta, reflejando la pobre capacidad predictiva de las participaciones de gasto en el caso de tarjetas de crédito. La curva del panel (b) –modelo tradicional– se eleva respecto de la diagonal y alcanza un AUC de aproximadamente 0,75, indicando que las variables socio-demográficas y de deuda capturan la mayor parte de la información relevante. El panel (c) muestra que el modelo combinado logra desplazar la curva hacia el borde superior izquierdo; aunque la mejora es más modesta que en los no bancarizados, el DT+DA domina al modelo tradicional en toda la franja de 0 a 0,8 de falsos positivos. El salto visual de la curva combinada sobre la curva DT revela que incluso un aporte limitado de la data de consumo puede traducirse en una reducción de los errores de clasificación.

5.1.3. Bancarizados 2021 – Curvas ROC y AUC


Gráfico 3: Curvas ROC – Hogares no bancarizados, año 2021.

El subgráfico 3.1 presenta el desempeño del modelo de consumo (DA) para los hogares bancarizados en 2021, estimado mediante una regresión logística donde la variable dependiente es el incumplimiento financiero y las variables explicativas corresponden únicamente a las participaciones de gasto. Este modelo alcanza un AUC cercano a 0,69, lo que indica que el gasto por sí solo contiene información limitada sobre el riesgo de incumplimiento. El subgráfico 3.2 muestra el desempeño del modelo tradicional (DT), basado exclusivamente en características sociodemográficas y financieras del jefe de hogar, donde la inclusión de la deuda total mejora sustancialmente la capacidad predictiva del modelo ($AUC \approx 0,90$). Finalmente, el subgráfico 3.3 presenta el modelo combinado (DT+DA), que integra simultáneamente las variables tradicionales y las participaciones de gasto, alcanzando un AUC cercano a 0,96. Las curvas mostradas en la figura corroboran la clara superioridad del modelo combinado en este grupo de hogares.


Subgráfico 3.1 (Modelo de consumo – DA): Curva ROC basada en `logit incumpl_consumo log_gasto_*`; muestra un $AUC \approx 0,69$ y refleja el poder predictivo limitado del gasto por sí solo.



Subgráfico 3.2 (Modelo demográfico – DT): Curva ROC para `logit incumpl_consumo nivel_educacional edad tipo_ocupacion log_ing_hogar estado_civil deuda_total`, donde la inclusión de la deuda total eleva el $AUC \approx 0,90$.



Subgráfico 3.3 (Modelo combinado – DT+DA): Curva ROC para logit incumpl_consumo nivel_educacional edad tipo_ocupacion log_ing_hogar estado_civil deuda_total log_gasto_*, alcanzando una AUC≈0,96.




El Gráfico 3 evidencia una notable mejora en la discriminación para el periodo 2021. La curva del panel (c) se adhiere al margen superior izquierdo, representando una AUC cercana a 0,96 y una casi perfecta capacidad de ordenamiento de hogares según su riesgo de incumplir. El panel (b) muestra que el modelo tradicional también experimenta un incremento marcado respecto a 2017 (AUC≈0,90), gracias a la incorporación de la deuda total como covariable. En contraste, la curva del panel (a) –modelo de consumo– se desplaza ligeramente hacia abajo en comparación con 2017, reflejando la caída en el poder predictivo de las participaciones de gasto durante la post pandemia. No obstante, el orden relativo de las curvas se mantiene: DT+DA > DT > DA, y la distancia entre el modelo combinado y los otros dos sigue siendo apreciable, lo que confirma que el consumo sigue aportando información incremental incluso cuando las variables tradicionales son muy fuertes.

5.1.4. No Bancarizados 2021 – Curvas ROC y AUC


Gráficos 4: Curvas ROC – Hogares bancarizados, año 2021.

El subgráfico 4.1 presenta el desempeño del modelo de consumo (DA) para los hogares no bancarizados en 2021, estimado mediante una regresión logística donde la variable dependiente corresponde al incumplimiento financiero y las variables explicativas son únicamente las participaciones de gasto imputadas de la EPF. En este caso, el modelo logra un AUC cercano a 0,68, indicando que la información de consumo por sí sola ofrece capacidad predictiva limitada. El subgráfico 4.2 muestra el desempeño del modelo tradicional (DT), basado exclusivamente en características sociodemográficas del jefe de hogar, alcanzando un AUC significativamente mayor (alrededor de 0,88). Finalmente, el subgráfico 4.3 presenta el modelo combinado (DT+DA), que integra simultáneamente las variables tradicionales y las participaciones de gasto, logrando un AUC cercano a 0,95. En conjunto, las curvas ROC muestran nuevamente que el modelo combinado supera al modelo tradicional y al modelo basado solo en consumo, confirmando patrones similares a los observados en otros grupos analizados.


Subgráfico 4.1 (Modelo de consumo – DA): Curva ROC para logit `incumpl_tarjeta log_gasto_*`; la AUC apenas supera 0,53, indicando que las participaciones de gasto son poco informativas en este segmento.



Subgráfico 4.2 (Modelo demográfico – DT): Curva ROC asociada al modelo logit incumpl_tarjeta nivel_educacional edad_ent tipo_ocupacion log_ing_hogar estado_civil cf_dtoth, con $AUC \approx 0,74$.



Subgráfico 4.3 (Modelo combinado – DT+DA): Curva ROC para logit incumpl_tarjeta nivel_educacional edad tipo_ocupacion log_ing_hogar estado_civil deuda_total log_gasto_*, donde se añade la deuda total y las participaciones de gasto; su $AUC \approx 0,80$.



En el Gráfico 4 se observa que los tres modelos para los hogares bancarizados en 2021 presentan curvas más cercanas entre sí que en los otros segmentos. La curva del panel (b) –modelo tradicional– supera claramente a la del panel (a) –modelo de consumo–, situándose por encima de la diagonal y reflejando un AUC aproximado de 0,74. El panel (c) muestra que el modelo combinado desplaza la curva ligeramente hacia el vértice superior izquierdo, logrando un AUC de alrededor de 0,80. La mejora visual es palpable pero modesta: el área entre la curva DT+DA y la curva DT es estrecha, lo que sugiere que, para los hogares con tarjeta de crédito en 2021, las participaciones de gasto agregan información predictiva pero en menor medida que en los otros grupos. La cercanía de las curvas indica que la mayor parte de la capacidad discriminatoria proviene de las variables demográficas y de deuda, con la data alternativa complementando de forma marginal.

5.2. Resultados econométricos: Modelos DT, DA y DA+DT

A continuación, se presentan los resultados de las estimaciones econométricas para los años 2017 y 2021. Se analizan los modelos tradicionales (DT), los modelos alternativos basados en consumo (DA) y los modelos combinados (DA+DT), distinguiendo entre hogares bancarizados y no bancarizados. Las tablas completas se encuentran en el **Anexo**.

5.2.1. Resultados 2017

a. Modelos tradicionales (DT)

En los hogares bancarizados, los predictores tradicionales muestran el comportamiento esperado (Tabla DT Bancarizados 2017, Anexo). Un mayor nivel educacional, una mayor edad y vivir en pareja se asocian significativamente con una menor probabilidad de incumplimiento, mientras que una mayor deuda total incrementa el riesgo. El pseudo- R^2 (0.119) refleja un desempeño adecuado del modelo para este grupo.

Entre los no bancarizados (Tabla DT No Bancarizados 2017, Anexo), la capacidad explicativa disminuye sustancialmente (pseudo- $R^2 \approx 0.05$). Solo edad (negativa) y estado civil (positiva) resultan significativas, mientras que educación, ingresos y ocupación no tienen efectos estadísticamente detectables. Esto indica que los predictores tradicionales pierden potencia en ausencia de historial crediticio formal.

b. Modelos alternativos basados en consumo (DA)

En los bancarizados (Tabla DA Bancarizados 2017, Anexo), ninguna de las categorías de gasto muestra significancia estadística y el pseudo- R^2 es extremadamente bajo (≈ 0.006). Esto confirma que la estructura del consumo no agrega información relevante cuando ya existe historial financiero.

En los no bancarizados, el modelo DA (Tabla DA No Bancarizados 2017, Anexo) incrementa el pseudo- R^2 a ~ 0.143 . Aunque pocos coeficientes individuales son significativos, los patrones son económicamente coherentes: gastos esenciales tienden a asociarse a menor riesgo, mientras que gastos más volátiles (bienes diversos, drogas) muestran coeficientes positivos. Esto sugiere que las decisiones de consumo capturan vulnerabilidad financiera en hogares excluidos del sistema formal.

c. Modelos combinados (DA+DT)

En los bancarizados (Tabla DA+DT Bancarizados 2017, Anexo), los modelos combinados reproducen casi exactamente el patrón del modelo tradicional: las variables tradicionales mantienen significancia, mientras que las categorías de gasto no aportan capacidad predictiva. Esto sugiere que la información tradicional es suficiente para explicar riesgo en este grupo.

En los no bancarizados, el modelo DA+DT (Tabla DA+DT No Bancarizados 2017, Anexo) obtiene la mayor capacidad predictiva del año (pseudo- $R^2 \approx 0.367$). Aunque los coeficientes individuales no siempre son significativos, el conjunto de variables basadas en consumo mejora sustancialmente el desempeño del modelo. Esto constituye evidencia sólida de que la combinación entre consumo y

predictores tradicionales es especialmente útil cuando no existe historial crediticio formal.

5.2.2. Resultados 2021

a. Modelos tradicionales (DT)

En 2021, los hogares bancarizados (Tabla DT Bancarizados 2021, Anexo) mantienen patrones consistentes con los observados en 2017. Mayor educación, edad, ingreso del hogar y estado civil estable reducen significativamente el riesgo, mientras que la deuda total lo incrementa. El pseudo- R^2 (0.089) es similar al obtenido en 2017.

Entre los no bancarizados (Tabla DT No Bancarizados 2021, Anexo), el modelo tradicional mejora su capacidad explicativa respecto a 2017 (pseudo- $R^2 \approx 0.21$). Destaca un coeficiente fuertemente negativo para nivel educacional, y coeficientes positivos y significativos para tipo de ocupación y estado civil, lo que refuerza la importancia de la educación como factor protector en este grupo.

b. Modelos alternativos basados en consumo (DA)

En los bancarizados (Tabla DA Bancarizados 2021, Anexo), los gastos continúan mostrando una capacidad predictiva muy limitada (pseudo- $R^2 \approx 0.002$). Solo dos ítems agua/electricidad y restaurant/hotelería resultan significativos, ambos con coeficientes positivos.

En los no bancarizados, el modelo DA para 2021 (Tabla DA No Bancarizados 2021, Anexo) revela una fuerte reducción en capacidad predictiva respecto a 2017 (pseudo- $R^2 \approx 0.018$). Esto sugiere que la pandemia alteró los patrones de consumo de manera que redujo la capacidad de estas variables para capturar vulnerabilidad financiera.

c. Modelos combinados (DA+DT)

En los bancarizados, los modelos combinados (Tabla DA+DT Bancarizados 2021, Anexo) vuelven a replicar el patrón del modelo tradicional: las variables demográficas y financieras son las que explican el riesgo, mientras que la estructura del gasto no agrega valor. El pseudo- R^2 se mantiene en torno a 0.110.

En los no bancarizados, el modelo DA+DT (Tabla DA+DT No Bancarizados 2021, Anexo) alcanza nuevamente el mejor desempeño del año (pseudo- $R^2 \approx 0.332$). Los efectos significativos corresponden a nivel educacional, ingreso del hogar, deuda total y gasto en agua/electricidad. Esto refuerza el hallazgo central del estudio: la estructura del gasto mejora sustancialmente la capacidad de predecir incumplimiento en hogares sin historial crediticio formal, incluso tras los cambios económicos de la pandemia.

5.3. Síntesis comparativa 2017–2021

La comparación interanual muestra estabilidad en los resultados. En ambos años, los modelos tradicionales explican bien el incumplimiento en hogares bancarizados, mientras que la información basada en consumo no aporta valor adicional. En contraste, entre los no bancarizados los modelos DA+DT son consistentemente los más acertados, con pseudo- R^2 entre 0.33 y 0.37. Aunque la pandemia

afectó los patrones de consumo, la combinación de información tradicional y consumo continúa siendo la estrategia de mayor capacidad predictiva en hogares excluidos del sistema financiero formal.

6. Discusión e implicancias

Los resultados obtenidos muestran que los patrones de consumo aportan información relevante para predecir el incumplimiento crediticio, especialmente cuando los hogares carecen de historial financiero formal. Esto tiene implicancias importantes tanto para los prestamistas como para el diseño de políticas públicas.

En primer lugar, la evidencia confirma que la composición del gasto contiene señales económicas que los modelos tradicionales no capturan totalmente. Para los hogares no bancarizados, las variables de consumo incrementan significativamente la capacidad predictiva, elevando la AUC-ROC de los modelos tradicionales y disminuyendo simultáneamente los errores de tipo I y tipo II. Dado que estos hogares no cuentan con burós de crédito o registros históricos, la estructura del gasto actúa como una fuente alternativa de información, permitiendo identificar niveles de liquidez, restricción presupuestaria y vulnerabilidad financiera. En la práctica, esto sugiere que los prestamistas podrían usar datos de consumo para otorgar crédito responsable en segmentos tradicionalmente excluidos.

En los hogares bancarizados, en cambio, las variables de consumo funcionan principalmente como un complemento marginal: la mayor parte del poder predictivo proviene de variables tradicionales como educación, ingreso y deuda total. Aun así, la inclusión de gasto discrecional y esencial permite ajustar ligeramente la clasificación, lo cual abre la puerta a calibraciones más finas en límites de crédito, monitoreo del riesgo y estrategias de gestión de cartera.

Desde una perspectiva de diseño de productos, los resultados sugieren que los no bancarizados requieren instrumentos específicos: microcréditos, líneas para construir historial financiero o productos con límites graduales basados en sus patrones de consumo. Para la población bancarizada, las señales de consumo podrían complementar los historiales crediticios para mejorar la asignación de tasas o detectar tempranamente estrés financiero.

También existen implicancias relevantes para las políticas públicas. Dado que las encuestas de hogares permiten inferir vulnerabilidad financiera con cierto grado de precisión, instituciones públicas podrían utilizarlas para monitorear el bienestar financiero, anticipar presiones sobre el endeudamiento y focalizar programas de apoyo. El hallazgo de que la participación del gasto en alimentos es un predictor robusto coincide con la literatura sobre restricciones presupuestarias y podría integrarse en algoritmos de focalización social.

No obstante, el uso de datos alternativos también exige consideraciones éticas y de equidad. Variables como gasto en alimentos pueden correlacionarse con condiciones estructurales de pobreza y, si se usan sin salvaguardas, podrían reforzar sesgos preexistentes. Por ello, cualquier aplicación práctica debe incluir auditorías periódicas de equidad algorítmica, transparencia modelada y mecanismos que permitan a los usuarios cuestionar decisiones automatizadas.

Finalmente, los resultados sugieren que las señales basadas en consumo son especialmente útiles en contextos macroeconómicos volátiles. Cambios abruptos en los patrones de gasto como los observados durante la pandemia pueden anticipar deterioros en la capacidad de pago antes de que se materialicen

en incumplimiento, lo cual es relevante tanto para prestamistas como para autoridades de supervisión financiera.

7. Conclusión

Este estudio demuestra que la data alternativa de consumo es una herramienta valiosa para enriquecer la evaluación del riesgo crediticio en Chile, especialmente entre hogares sin historial financiero formal. Al combinar la EPF y la EFH mediante propensity score matching, fue posible construir una base unificada que integra información granular de gasto con indicadores de endeudamiento y morosidad, permitiendo evaluar de manera rigurosa el aporte de cada conjunto de variables.

Los resultados indican que la composición del consumo en particular la participación del gasto en alimentos, transporte y recreación aporta información adicional que mejora la capacidad de distinguir entre hogares que incumplirán y hogares que no lo harán. Si bien los modelos tradicionales siguen siendo más efectivos en los segmentos bancarizados, la data alternativa incrementa significativamente el poder predictivo en los no bancarizados y consumidores thin-file, actuando como sustituto parcial del historial crediticio que estas personas no poseen.

Estos hallazgos contribuyen al debate sobre el uso responsable de datos alternativos en la evaluación crediticia. A diferencia de fuentes altamente sofisticadas o privadas (como búsquedas en internet o huellas digitales), este trabajo muestra que indicadores simples obtenidos de encuestas públicas pueden generar modelos predictivos más justos, transparentes y económicamente relevantes, lo cual es especialmente valioso en países donde la infraestructura digital aún es limitada.

El estudio también reconoce sus limitaciones, la imputación basada en emparejamiento introduce error de medición, la morosidad autoreportada puede contener sesgos, y el diseño transversal no permite establecer relaciones causales. Además, no se evaluaron métricas de equidad ni los potenciales efectos adversos de usar datos de consumo en poblaciones vulnerables.

Futuras investigaciones podrían incorporar datos panel, explorar variaciones dinámicas del gasto, evaluar el impacto de shocks macroeconómicos y comparar los resultados con otros países. Asimismo, sería relevante estudiar modelos de machine learning más complejos y evaluar cómo equilibrar precisión con interpretabilidad y equidad.

En conjunto, los resultados muestran que la convergencia entre datos de consumo y modelos de scoring crediticio tiene el potencial de ampliar la inclusión financiera, reducir rechazos injustificados y mejorar la asignación de riesgo. Para aprovechar completamente este potencial será necesario fortalecer la protección de datos, promover marcos regulatorios adecuados y avanzar en educación financiera que permita a los consumidores beneficiarse de estas nuevas herramientas.

8. Referencias

- Agarwal, S., Almeida, R., Morais, B., & Pan, J. (2020). What's so alternative about alternative data? Credit scoring using bank account information. NBER Working Paper No. 28587. National Bureau of Economic Research.
- Banco Central de Chile. (2018). Encuesta Financiera de Hogares 2017: Principales resultados. Banco Central de Chile.
- Banco Central de Chile. (2022). Encuesta Financiera de Hogares 2021: Documento de resultados. Banco Central de Chile.
- Berg, T., Burg, V., Gombović, A., & Puri, M. (2020). On the rise of fintechs: Credit scoring using digital footprints. *Journal of Consumer Financial Studies*, 3–27.
- Björkegren, D., & Grissen, D. (2020). Behavior revealed in mobile phone usage predicts credit repayment. *The World Bank Economic Review*, 757–784.
- Cuttillo, A., & Scanu, M. (2020). Statistical matching of income and consumption surveys: An application to inequality analysis. *Review of Income and Wealth*, 520–550.
- Dagoberto Ojeda, R. G. (2016). Puntuación de riesgo cardiovascular: Limitaciones y uso clínico. *Revista Médica de Chile*, 343–351.
- Djeundje, V. B., Crook, J., Calabrese, R., & Hamel, S. (2021). Flexible credit scoring using shape-restricted functions. *European Journal of Operational Research*, 830–841.
- Gross, D., & Souleles, N. (2002). Do consumption patterns predict bankruptcy? Evidence from credit card data. *The Quarterly Journal of Economics*, 149–185.
- Instituto Nacional de Estadísticas. (2018). VIII Encuesta de Presupuestos Familiares 2016-2017. Instituto Nacional de Estadísticas.
- Instituto Nacional de Estadísticas. (2023). IX Encuesta de Presupuestos Familiares 2021-2022: Informe de principales resultados. Instituto Nacional de Estadísticas.
- Khandani, A., Kim, A., & Lo, A. (2010). Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, 2767–2787.
- Priestley, J. L., & VonDohlen, E. (2024). Propensity score matching: A tool for consumer risk modeling and portfolio underwriting. *Journal of Applied Statistics*, 2481–2488.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 41–55.

9. Apéndice

Apéndice 1: Modelo DT Bancarizados 2021

VARIABLES	(1) Incumple Tarjeta
nivel_educacional	-0.170*** (0.046)
edad_ent	-0.042*** (0.003)
tipo_ocupacion	0.079 (0.111)
log_ing_hogar	-0.598*** (0.063)
estado_civil	-0.120*** (0.045)
cf_dtoth	0.000*** (0.000)
Constant	8.412*** (0.824)
Observations	8,279
Pseudo-R2	0.0894

Standard errors in parentheses

*** p<0.01, ** p<0.05, * p<0.1

Apéndice 2: Modelo DA Bancarizados 2021

VARIABLES	(1) Incumple Tarjeta
log_gasto_alimentos	-0.004 (0.004)
log_gasto_drogas	-0.001 (0.002)
log_gasto_vestimenta	-0.001 (0.003)
log_gasto_agua_electricidad	0.008** (0.003)
log_gasto_articulos_hogar	-0.001 (0.003)
log_gasto_salud	-0.004 (0.003)
log_gasto_transporte	-0.001 (0.003)
log_gasto_comunicacion	-0.001 (0.003)
log_gasto_recreacion	0.002 (0.003)
log_gasto_educacion	0.000 (0.007)
log_gasto_restaurant_hoteleria	0.005** (0.003)
log_gasto_BS_diversos	-0.001 (0.003)
Constant	-2.106*** (0.179)
Observations	8,563
Pseudo-R2	0.00224

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 3: Modelo Complementario DA+DT Bancarizados 2021

VARIABLES	(1) Incumple Tarjeta
nivel_educacional	-0.189*** (0.049)
edad_ent	-0.046*** (0.004)
tipo_ocupacion	0.120 (0.119)
log_ing_hogar	-0.695*** (0.068)
estado_civil	-0.533*** (0.086)
cf_dtoth	0.000*** (0.000)
log_gasto_alimentos	-0.006 (0.006)
log_gasto_drogas	0.002 (0.003)
log_gasto_vestimenta	0.004 (0.004)
log_gasto_agua_electricidad	0.014*** (0.004)
log_gasto_articulos_hogar	-0.005 (0.004)
log_gasto_salud	-0.005 (0.004)
log_gasto_transporte	-0.004 (0.004)
log_gasto_comunicacion	-0.001 (0.004)
log_gasto_recreacion	0.004 (0.003)
log_gasto_educacion	0.000 (0.009)
log_gasto_restaurant_hoteleria	0.008** (0.003)
log_gasto_BS_diversos	0.000 (0.004)
Constant	10.339*** (0.900)
Observations	7,681
Pseudo-R2	0.110

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 4: Modelo DT No Bancarizados 2021

VARIABLES	(1)
	Incumple Consumo
nivel_educacional	-1.811*** (0.315)
edad	-0.018 (0.014)
tipo_ocupacion	2.742*** (0.864)
log_ing_hogar	0.465 (0.409)
estado_civil	0.396*** (0.144)
deuda_total	0.000*** (0.000)
Constant	-7.375 (5.967)
Observations	1,404
Pseudo-R2	0.209

Standard errors in parentheses

*** p<0.01, ** p<0.05, * p<0.1

Apéndice 5: Modelo DA No Bancarizados 2021

VARIABLES	(1)
	Incumple Consumo
log_gasto_alimentos	0.001 (0.017)
log_gasto_drogas	-0.014 (0.009)
log_gasto_vestimenta	-0.015 (0.010)
log_gasto_agua_electricidad	0.018 (0.013)
log_gasto_articulos_hogar	0.006 (0.013)
log_gasto_salud	-0.003 (0.010)
log_gasto_transporte	0.009 (0.012)
log_gasto_comunicacion	-0.000 (0.012)
log_gasto_recreacion	0.009 (0.010)
log_gasto_educacion	-0.012 (0.026)
log_gasto_restaurant_hoteleria	0.007 (0.009)
log_gasto_BS_diversos	0.008 (0.010)
Constant	-3.814*** (0.731)
Observations	1,485
Pseudo-R2	0.0176

Standard errors in parentheses

*** p<0.01, ** p<0.05, * p<0.1

Apéndice 6: Modelo Complementario DA+DT No Bancarizados 2021

VARIABLES	(1)
	Incumple Consumo
nivel_educacional	-3.037*** (0.490)
edad	-0.013 (0.018)
o.tipo_ocupacion	-
log_ing_hogar	-1.574*** (0.510)
estado_civil	0.491 (0.344)
deuda_total	0.000*** (0.000)
log_gasto_alimentos	-0.003 (0.027)
log_gasto_drogas	-0.015 (0.014)
log_gasto_vestimenta	0.007 (0.015)
log_gasto_agua_electricidad	0.045** (0.021)
log_gasto_articulos_hogar	0.023 (0.022)
log_gasto_salud	-0.022 (0.015)
log_gasto_transporte	0.002 (0.018)
log_gasto_comunicacion	-0.009 (0.019)
log_gasto_recreacion	-0.006 (0.016)
log_gasto_educacion	-0.032 (0.041)
log_gasto_restaurant_hoteleria	0.009 (0.015)
log_gasto_BS_diversos	0.010 (0.016)
Constant	-18.934** (7.587)
Observations	928
Pseudo-R2	0.332

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 7: Modelo DT Bancarizados 2017

VARIABLES	(1) Incumple Tarjeta
nivel_educacional	-0.627*** (0.046)
edad_ent	-0.044*** (0.004)
tipo_ocupacion	0.181 (0.123)
log_ing_hogar	-0.004 (0.041)
estado_civil	-0.075*** (0.028)
cf_dtoth	0.000*** (0.000)
Constant	2.055*** (0.540)
Observations	6,068
Pseudo-R2	0.119

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 8: Modelo DA Bancarizados 2017

VARIABLES	(1) Incumple Tarjeta
log_gasto_alimentos	0.013 (0.015)
log_gasto_drogas	0.003 (0.011)
log_gasto_vestimenta	-0.025 (0.027)
log_gasto_electricidad	-0.006 (0.010)
log_gasto_articulos_hogar	0.007 (0.013)
log_gasto_salud	-0.003 (0.012)
log_gasto_transporte	0.008 (0.013)
log_gasto_comunicaciones	0.007 (0.009)
log_gasto_recreacion	-0.021 (0.013)
log_gasto_educacion	-0.008 (0.007)
log_gasto_restaurant_hoteleria	-0.010 (0.012)
log_gasto_BS_diversos	0.019 (0.022)
Constant	-1.484 (1.289)

Observations 1,867
Pseudo-R2 0.00618

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 9: Modelo Complementario DA+DT Bancarizados 2017

VARIABLES	(1) Incumple Tarjeta
nivel_educacional	-0.515*** (0.084)
edad_ent	-0.038*** (0.007)
tipo_ocupacion	0.194 (0.241)
log_ing_hogar	-0.030 (0.077)
estado_civil	-0.018 (0.050)
deuda_total	0.000*** (0.000)
log_gasto_alimentos	0.009 (0.017)
log_gasto_drogas	-0.003 (0.013)
log_gasto_vestimenta	-0.024 (0.029)
log_gasto_electricidad	-0.002 (0.011)
log_gasto_articulos_hogar	0.007 (0.014)
log_gasto_salud	-0.000 (0.014)
log_gasto_transporte	0.013 (0.015)
log_gasto_comunicaciones	-0.001 (0.010)
log_gasto_recreacion	-0.013 (0.016)
log_gasto_educacion	-0.009 (0.008)
log_gasto_restaurant_hoteleria	-0.005 (0.014)
log_gasto_BS_diversos	0.020 (0.025)
Constant	1.860 (1.775)
Observations	1,752
Pseudo-R2	0.104

Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 10: Modelo DT No Bancarizados 2017

VARIABLES	(1)
	Incumple Consumo
nivel_educacional	-0.134 (0.212)
edad	-0.023* (0.013)
tipo_ocupacion	0.293 (0.489)
log_ing_hogar	0.291 (0.279)
estado_civil	0.318*** (0.113)
Deuda_toal	0.000 (0.000)
Constant	-7.310** (3.678)
Observations	1,631
Pseudo-R2	0.0523

Standard errors in parentheses

*** p<0.01, ** p<0.05, * p<0.1

Apéndice 11: Modelo DA No Bancarizados 2017

VARIABLES	(1)
	Incumple Consumo
log_gasto_alimentos	-0.125 (0.091)
log_gasto_drogas	0.123 (0.084)
log_gasto_vestimenta	0.433 (0.409)
log_gasto_electricidad	0.058 (0.049)
log_gasto_articulos_hogar	-0.060 (0.051)
log_gasto_salud	-0.008 (0.052)
log_gasto_transporte	0.014 (0.060)
log_gasto_comunicaciones	-0.053 (0.039)
log_gasto_recreacion	-0.068 (0.042)
log_gasto_educacion	-0.021 (0.031)
log_gasto_restaurant_hoteleria	0.057 (0.057)
log_gasto_BS_diversos	0.266 (0.227)
Constant	-25.837 (16.478)

Observations 432
Pseudo-R2 0.143
Standard errors in parentheses
*** p<0.01, ** p<0.05, * p<0.1

Apéndice 12: Modelo Complementario DA+DT No Bancarizados 2017

VARIABLES	(1) Incumple Consumo
nivel_educacional	0.602 (0.479)
edad_ent	0.045 (0.041)
tipo_ocupacion	2.223 (1.501)
log_ing_hogar	-0.215 (0.368)
estado_civil	0.490 (0.334)
cf_dtoth	-0.000 (0.000)
log_gasto_alimentos	-0.300 (0.282)
log_gasto_drogas	0.276 (0.256)
log_gasto_vestimenta	0.767 (0.709)
log_gasto_electricidad	1.007 (0.893)
log_gasto_articulos_hogar	-0.047 (0.104)
log_gasto_salud	-0.024 (0.080)
log_gasto_transporte	-0.042 (0.086)
log_gasto_comunicaciones	0.023 (0.074)
log_gasto_recreacion	-0.162** (0.073)
log_gasto_educacion	-0.039 (0.048)
log_gasto_restaurant_hoteleria	-0.002 (0.085)
log_gasto_BS_diversos	0.577 (0.521)
Constant	-81.688** (41.555)
Observations	403
Pseudo-R2	0.367
Standard errors in parentheses *** p<0.01, ** p<0.05, * p<0.1	